

연속 좌표 회귀를 위한 재귀적 정제 모델의 아키텍처 교정 및 수리적 안정성 분석 보고서

1. 서론 (Introduction)

최근 인공지능 연구의 흐름은 거대 언어 모델(LLM)의 파라미터 확장 법칙(Scaling Laws)을 넘어서, 작은 모델이 반복적인 사고 과정을 통해 성능을 증폭시키는 재귀적 추론(**Recursive Reasoning**) 패러다임으로 전환되고 있다. 특히 **Tiny Recursive Model (TRM)**¹과 **Deep Improvement Supervision (DIS)**¹는 ARC-AGI와 같은 고난도 불연속 기호 추론(Symbolic Reasoning) 작업에서 획기적인 성과를 입증하였다.

그러나 본 보고서의 의뢰인이 제기한 바와 같이, 이러한 이산적(discrete) 추론에 최적화된 아키텍처를 연속 좌표 회귀(**Soccer Data, Spatiotemporal Tracking**) 문제에 직접 적용할 경우, 심각한 수리적 불안정성이 관측된다. 특히 정제 단계가 거듭될수록 성능이 오히려 하락하는 '**\$s=2\$** 성능 저하(**Paradoxical Degradation**)' 현상과, 반복적인 학습에도 불구하고 오차가 특정 하한선에서 멈추는 '**13.2m MAE** 정체(**Plateau**)' 현상은 재귀적 신경망이 연속 공간(Continuous Manifold)에서 겪는 동역학적 불안정성을 시사한다.

본 보고서는 크게 세 부분으로 구성된다. 첫째, 기존 분석(Part 1)에서 오인되었던 TRM 및 DIS의 핵심 아키텍처를 원전 논문에 근거하여 정밀하게 교정한다. 둘째, 수정된 아키텍처 이해를 바탕으로 축구 선수 추적 데이터에서 발생하는 **\$s=2\$** 붕괴와 13.2m 정체 현상의 원인을 '립시츠 연속성(Lipschitz Continuity)' 위배와 '이점 마진(Advantage Margin)' 소실의 관점에서 규명한다. 셋째, 이를 해결하기 위해 연속 신뢰 영역 개선(**Continuous Trust-Region Improvement, CTRI**) 손실 함수와 스펙트럼 정규화(**Spectral Normalization**) 기반의 학습 전략을 제안하여, 모델이 수리적으로 보장된 수렴성을 갖도록 한다.

2. 아키텍처 교정: TRM과 DIS의 본질적 구조 (Architectural Rectification)

문제의 원인을 진단하기에 앞서, 기존 분석(Part 1)에서 혼동되었을 가능성이 높은 TRM과 DIS의 구조적 오해를 바로잡는 것이 필수적이다. TRM과 DIS는 단순한 RNN(Recurrent Neural Network)이 아니며, HRM(Hierarchical Reasoning Model)과는 본질적으로 다른 위상을 가진다.

2.1 오해와 진실: 단일 네트워크 통합 구조 (Unified Single-Network Topology)

가장 빈번하게 발생하는 오해는 재귀적 추론을 위해 서로 다른 주파수(frequency)로 작동하는 두 개의 별도 네트워크(저수준 **\$f_L\$** 및 고수준 **\$f_H\$**)가 필요하다는 인식이다. 이는 HRM의 특징이며, TRM은 이를 정면으로 반박하며 등장한 모델이다.

- 오해 (**Misconception - Part 1**): 모델이 '빠른 직관'을 담당하는 네트워크와 '느린 추론'을 담당하는 네트워크로 분리되어 있으며, 이들 간의 계층적 상호작용을 통해 추론이 이루어진다.
- 교정 (Correction - TRM Paper ¹): TRM은 "Less is More" 철학에 기반하여, 계층적 구조를 ****단일 초소형 네트워크(Single Tiny Network)****로 통합하였다. TRM은 약 7백만(7M) 파라미터 수준의 단일 Transformer 블록만을 사용하며, 이 하나의 네트워크가 '잠재적 추론(\$z\$)'과 '해답 생성(\$y\$)'을 모두 수행한다.

이러한 가중치 공유(**Weight Sharing**) 구조는 연속 회귀 문제에서 양날의 검으로 작용한다. 동일한 가중치 행렬 W 가 초기 추정 ($s=1$)과 정밀 보정 ($s=2$)에 모두 사용되기 때문에, 초기 단계에서 큰 보폭(Large Step Size)을 학습한 가중치가 후속 정밀 단계에서도 과도한 수정(Overshoot)을 유발할 수 있다. 이는 $s=2$ 성능 저하의 직접적인 구조적 원인이 된다.

2.2 상태 변수 재해석: z 와 y 의 비대칭적 역할

HRM은 생물학적 영감을 받아 z_L (Low-level latent)과 z_H (High-level latent)라는 계층적 잠재 변수를 사용했으나, TRM은 이를 기능적으로 재정의한다.¹

- **y (Current Answer State)**: 기존의 z_H 에 해당한다. 이는 현재 시점에서의 임베딩된 해답이다. 즉, 출력 헤드(Output Head)를 통과하면 즉시 예측 좌표(축구 선수의 위치)로 변환될 수 있는 상태이다.
- **z (Latent Reasoning State)**: 기존의 z_L 에 해당한다. 이는 해답으로 직접 변환되지 않는 ****작업 기억(Working Memory)****이자 '사고의 흔적(Chain of Thought)'이다. z 는 이전 단계의 오차 패턴이나 운동량(Momentum) 정보를 암묵적으로 저장하여 다음 단계의 y 업데이트 방향을 결정하는 나침반 역할을 한다.

TRM의 재귀 루프는 다음과 같은 비대칭 업데이트를 수행한다¹:

1. **Reasoning Update**: $z_{t+1} \leftarrow f_{\theta}(x, y_t, z_t)$ (입력 x 를 참조하여 추론 상태 갱신)
2. **Answer Update**: $y_{t+1} \leftarrow f_{\theta}(y_t, z_{t+1})$ (갱신된 추론 상태를 바탕으로 해답 수정)

축구 데이터 회귀 문제에서 z 를 단순히 y 의 복사본이나 노이즈가 섞인 버전으로 취급했다면, 모델은 '이동의 맥락'을 기억하지 못하고 매 단계마다 독립적인 추정을 반복하게 되어 13.2m 오차에서 정체될 수밖에 없다.

2.3 DIS의 지도 신호: 이산 확산과 연속 회귀의 불일치

DIS(Deep Improvement Supervision)의 핵심은 최종 결과만 학습하는 것이 아니라, 중간 단계의 목표값($y^{\dagger}_s$)을 명시적으로 제공하는 것이다.¹

- 기존 **DIS**의 메커니즘: 원전 논문에서 DIS는 이산 확산(**Discrete Diffusion**) 과정을 역설계하여 목표를 생성한다. 예를 들어, 정답 토큰의 일부를 마스킹하거나 무작위로 치환한 뒤, 단계별로 이를 복원하도록 훈련한다. 이는 각 단계가 검증 가능한 개선(Verifiable Improvement)을 이루도록 강제한다.

- 연속 회귀에서의 오적용 가능성: Part 1에서 만약 DIS를 좌표 회귀에 적용하면서 단순히 '선형 보간(Linear Interpolation)'이나 '동일한 정답 반복(Identical Target)'을 사용했다면, 이는 DIS의 '이점 마진(Advantage Margin)' 원리를 위배하는 것이다. 연속 공간에서는 단순 보간이 실제 물리적 개선 경로(Gradient Flow)와 일치하지 않으며, 이는 모델에게 혼란스러운 지도 신호를 제공하게 된다.

3. 연속 좌표 회귀에서의 실패 역학 분석 (Failure Dynamics Analysis)

교정된 아키텍처 이해를 바탕으로, 사용자 데이터(Soccer Data)에서 관측된 두 가지 병리 현상을 심층 분석한다.

3.1 현상 1: $s=2$ 성능 저하 (Paradoxical Iterative Degradation)

일반적으로 반복 추론은 단계가 거듭될수록 성능이 향상되어야 한다. 그러나 $s=2$ 에서 성능이 급격히 하락하는 현상은 **수치적 불안정성(Numerical Instability)**과 **노출 편향(Exposure Bias)**의 결합으로 설명된다.

3.1.1 확장적 자코비안(Expansive Jacobian)과 립시츠 상수 위배

재귀적 업데이트 함수를 $y_{s+1} = \mathcal{T}(y_s, z_s)$ 라고 할 때, 이 시스템이 수렴하기 위해서는 함수 $\mathcal{T}$ 가 해당 영역에서 **축소 사상(Contraction Mapping)**이어야 한다. 즉, 립시츠 상수 $L < 1$ 이어야 한다.²

$$\|\mathcal{T}(y_a) - \mathcal{T}(y_b)\| \leq L \|y_a - y_b\|$$

- 초기 단계의 딜레마: $s=1$ 단계에서 모델은 무작위 초기화 상태에서 실제 선수 위치 근처로 좌표를 크게 이동시켜야 한다. 이를 위해 네트워크는 가중치 행렬 W 의 스펙트럼 반경(Spectral Radius, 가장 큰 고윳값의 절댓값)을 1보다 훨씬 크게 설정하여($\rho(W) \gg 1$) 높은 이득(High Gain)을 확보하려 한다.
- 재귀의 저주: TRM은 단일 네트워크이므로, $s=2$ 에서도 동일한 고이득 가중치 W 가 사용된다. $s=1$ 의 결과물 y_1 은 정답 y^* 근처에 도달해 있어 미세한 수정만 필요함에도 불구하고, 네트워크는 여전히 큰 폭의 수정 벡터를 생성한다. 이는 좌표를 정답 너머로 튕겨내버리는 오버슈트(Overshoot) 현상을 유발하며, 결과적으로 $s=2$ 의 오차가 $s=1$ 보다 커지게 된다.⁴

3.1.2 연속 공간에서의 노출 편향 (Continuous Exposure Bias)

DIS 학습 시에는 각 단계의 입력으로 '이상적인 중간 목표($y^{\dagger}_{s-1}$)'가 제공된다. 그러나 추론(Inference) 시에는 모델이 이전 단계에서 예측한 값($\hat{y}_{s-1}$)이 입력으로 들어간다.⁶

- 분포 이탈(Distribution Shift): $\hat{y}_{s-1} = y^{\dagger}_{s-1} + \epsilon$ (여기서

ϵ 은 1단계 오차). 이산 토큰의 경우 $\arg\max$ 를 통해 ϵ 을 제거할 수 있지만, 연속 좌표에서는 오차 ϵ 이 그대로 다음 단계로 전파된다.

- 오차 증폭: 모델은 학습 과정에서 ϵ 만큼 떨어진 좌표(Off-manifold)에서 복원하는 방법을 배운 적이 없다. 따라서 $s=2$ 에서 입력된 노이즈가 섞인 좌표를 낯선 데이터로 인식하여 엉뚱한 방향으로 갱신하게 되며, 이는 오차를 기하급수적으로 증폭시킨다.

3.2 현상 2: 13.2m MAE 정체 (The 13.2m Plateau)

오차가 0으로 수렴하지 않고 13.2m라는 특정 값에서 정체되는 현상은 모델이 ***안전한 평균(Safe Mean)**으로 수렴했음을 의미한다.

3.2.1 평균 추구 붕괴 (Mean-Seeking Collapse)

촉구 데이터는 센서 노이즈나 가려짐(Occlusion) 등으로 인해 불확실성(Aleatoric Uncertainty)을 내포한다. MSE(Mean Squared Error) 손실 함수는 불확실한 분포의 **조건부 평균(Conditional Mean)**을 예측하도록 모델을 유도한다.⁷

- $s=1$ 단계에서 모델은 가능한 위치들의 평균점으로 이동한다.
- 이후 단계에서 모델은 더 이상 구체적인 위치를 특정할 정보(z 의 용량 한계)가 없으므로, 평균점 주변을 배회하거나(Random Walk), 업데이트를 멈추는 것이 전체 손실을 최소화하는 전략임을 학습하게 된다. 13.2m는 해당 데이터셋이 가진 내재적 불확실성의 반경(Noise Floor)일 가능성이 높다.

3.2.2 이점 마진 조건(Advantage Margin Condition)의 실패

DIS 논문¹은 "정답 클래스에 대한 로짓 상승분이 오답 클래스에 대한 평균 상승분보다 커야 한다"는 이점 마진 조건을 제시한다. 이를 연속 공간으로 치환하면 그래디언트 정렬(Gradient Alignment) 조건이 된다.

$$\angle \nabla_{\text{update}}, \vec{v}_{\text{error}} \rangle > 0$$

즉, 모델이 생성한 업데이트 벡터가 실제 오차 벡터와 예각(positive cosine similarity)을 이루어야 한다. 그러나 13.2m 반경 내에서는 모델의 업데이트 벡터가 실제 오차 방향과 무관한 임의의 방향(노이즈)을 가리키게 되어, 유효한 정제가 일어나지 않고 정체되는 것이다.¹

4. 수리적 안정성 확보 전략: 손실 함수 및 학습 전략 제안

상기 분석된 불안정성을 해결하기 위해, 립시츠 연속성을 강제하고 연속 공간에서의 신뢰 영역(Trust Region)을 설정하는 새로운 솔루션을 제안한다.

4.1 제안된 손실 함수: CTRI (Continuous Trust-Region Improvement)

기존의 단순 MSE 손실 함수는 재귀적 발산을 제어하지 못한다. 이를 대체할 CTRI 손실 함수를 다음과 같이 정의한다.

$$\mathcal{L}_{\text{CTRL}} = \sum_{s=1}^{N_{\text{sup}}} \omega_s \left(\underbrace{\|\hat{y}_s - y^*\|_2^2}_{\text{Task Accuracy}} + \lambda_1 \underbrace{\mathcal{R}(\hat{y}_s, \hat{y}_{s-1}, y^*)}_{\text{Monotonicity}} + \lambda_2 \underbrace{\|\hat{y}_s - \hat{y}_{s-1}\|_2^2}_{\text{Kinetic/Trust Penalty}} \right)$$

이 손실 함수의 각 항은 다음과 같은 수리적 역할을 수행한다.

1. 단조 개선 제약 (Monotonic Improvement Constraint, $\mathcal{R}$)

$s=2$ 에서의 성능 저하를 원천 차단하기 위해, 이전 단계보다 오차가 커질 경우 강력한 페널티를 부과한다.

$$\mathcal{R} = \text{ReLU}(\|\hat{y}_s - y^*\|_2 - \gamma \|\hat{y}_{s-1} - y^*\|_2)$$

여기서 $\gamma \leq 1$ 은 감쇠 계수이다. 이 항은 모델이 "확신이 없다면 최소한 이전 위치를 유지(Identity Mapping)"하도록 강제하여 발산을 방지한다.⁸

2. 운동 에너지/신뢰 영역 페널티 (Kinetic/Trust Penalty)

$$\|\hat{y}_s - \hat{y}_{s-1}\|_2^2$$

이 항은 모델이 한 번의 업데이트(s)에서 이동할 수 있는 거리를 제한한다. 이는 업데이트 함수 ϕ 의 립시츠 상수를 간접적으로 제어하여, 초기 단계의 큰 가중치가 후반부에서 오버슈트를 일으키지 않도록 '브레이크' 역할을 한다.⁹

3. 단계별 가중치 (ω_s)

초기 단계보다 후반 단계에 더 큰 가중치($\omega_s = s^2$)를 부여한다. 이는 모델이 $s=1$ 에서 대충 맞추고 끝내는 것이 아니라, $s=16$ 까지 미세 조정을 멈추지 않도록 유도하여 13.2m 정체를 돌파하게 한다.

4.2 아키텍처 수정: 스펙트럼 정규화 (Spectral Normalization)

손실 함수만으로는 학습 과정에서의 급격한 그래디언트 폭발을 막기 어렵다. 모델의 가중치 행렬 W 자체에 제약을 가해야 한다.

- 제안: TRM의 모든 재귀적 레이어(Self-Attention, MLP)에 스펙트럼 정규화(Spectral Normalization)¹¹를 적용한다.
- 효과: 스펙트럼 정규화는 가중치 행렬의 스펙트럼 반경 $\sigma(W)$ 를 1로 제한한다. 이는 네트워크 전체의 립시츠 상수가 1을 넘지 않도록 보장하여, 입력의 작은 노이즈가 재귀를 반복해도 증폭되지 않고 유지되거나 감소하도록 만든다. 이는 '안정적인 재귀(Stable Recursion)'를 위한 가장 강력한 수리적 안전장치이다.

4.3 학습 전략: 연속 노이즈 주입 및 커리큘럼 (Training Strategy)

이산적 마스킹 대신, 연속 공간에 적합한 노이즈 주입 전략을 사용해야 한다.

1. 가우시안 디노이징 훈련 (Gaussian Denoising Training)

DIS의 중간 목표 생성을 위해 선형 보간 대신 가우시안 노이즈를 사용한다.

- 학습 시 s 단계의 입력으로 y_{s-1} 대신 $y^{\dagger}_s + \mathcal{N}(0, \sigma_s)$ 를 주입한다.
- 모델은 노이즈가 섞인 좌표를 받아 정답 y^* 방향으로 복원(Denoising)하는 것을 학습한다. 이는 추론 시 발생하는 오차 ϵ 을 '노이즈'로 인식하고 수정할 수 있는 내성(Robustness)을 길러주어 $s=2$ 붕괴를 막는다.⁷

2. 동적 정지 게이팅 (Adaptive Gating Mechanism)

TRM 네트워크에 학습 가능한 게이트 스칼라 α 를 추가한다.

$$y_{s+1} = y_s + \tanh(\alpha_s(z_s)) \cdot \Delta_{\text{net}}(y_s, z_s)$$

13.2m 근처에 도달하면 추론 상태 z_s 가 이를 감지하여 $\alpha_s \rightarrow 0$ 으로 수렴하도록 한다. 이는 더 이상의 무의미한 진동(Jittering)을 억제하고 수렴을 안정화시킨다.¹³

5. 결론 (Conclusion)

본 보고서는 TRM과 DIS 아키텍처에 대한 오해를 바로잡고, 축구 데이터 회귀 문제에서 발생하는 성능 저하의 원인을 분석하였다. TRM은 단일 네트워크로서 가중치를 공유하기 때문에, 초기 단계의 큰 업데이트가 후속 단계에서 불안정성을 야기하는 구조적 위험을 안고 있다. $s=2$ 붕괴는 이러한 **확장적 동역학(Expansive Dynamics)**의 결과이며, 13.2m 정체는 불확실성 하에서의 평균 추구(Mean-Seeking) 현상이다.

이를 해결하기 위해 제안된 **CTRI** 손실 함수는 단조 개선과 신뢰 영역 제약을 통해 재귀의 방향성을 강제하며, 스펙트럼 정규화는 네트워크 자체가 축소 사상(Contraction Mapping)이 되도록 보장한다. 또한 가우시안 디노이징 학습 전략은 연속 공간에서의 노출 편향을 해결하여, 모델이 스스로의 오차를 보정할 수 있게 한다. 이 전략들을 통합 적용함으로써, TRM+DIS 모델은 연속 좌표 공간에서도 이산적 작업에서 보여준 것과 같은 강력하고 안정적인 재귀적 정체 성능을 발휘할 수 있을 것으로 확신한다.

핵심 요약표 (Summary Table)

구분	기존 접근 (Part 1 / 현황)	제안된 해결책 (Proposed Solution)	기대 효과

아키텍처	이원화된 네트워크 (오해)	단일 가중치 공유 TRM + 게이팅	파라미터 효율성 및 수렴 제어
손실 함수	단순 MSE / 이산 Cross-Entropy	CTRI (단조성 + 신뢰 영역 제약)	$\$s=2\$$ 붕괴 방지 및 오버슈트 억제
안정화 기법	없음 (Unconstrained)	스펙트럼 정규화 (Lip $\\$ \approx \\$ 1$)	그라디언트 폭발 방지, 수렴 보장
학습 타겟	선형 보간 / 이산 마스킹	가우시안 디노이징 (Denoising)	노출 편향 해결, 강건성 확보
결과	13.2m 정제 및 발산	미세 정제 (Fine-grained Refinement)	정밀도 향상 및 단조 수렴

참고 자료

1. TRM.pdf
2. Contraction Theory for Optimization, Control, and Neural Networks - arXiv, 1월 3, 2026에 액세스, <https://arxiv.org/html/2404.11707v1>
3. Contracting Implicit Recurrent Neural Networks: Stable Models with Improved Trainability - OpenReview, 1월 3, 2026에 액세스, https://openreview.net/pdf?id=7ZxDcM_ZScZ
4. DPAD: Distribution-Driven Perturbation-Adaptive Defense for UAV Time-Series Regression Under Hybrid Adversarial Attacks - MDPI, 1월 3, 2026에 액세스, <https://www.mdpi.com/2504-446X/9/12/828>
5. DiG-Flow: Discrepancy-Guided Flow Matching for Robust VLA Models - arXiv, 1월 3, 2026에 액세스, <https://arxiv.org/html/2512.01715v1>
6. Rethinking Training Dynamics in Scale-wise Autoregressive Generation - arXiv, 1월 3, 2026에 액세스, <https://arxiv.org/html/2512.06421v1>
7. Stochastic Self-Guidance for Training-Free Enhancement of Diffusion Models - OpenReview, 1월 3, 2026에 액세스, <https://openreview.net/forum?id=9RyRlyzgT5>
8. Accelerating Training of Recursive Reasoning Models with Curriculum Guided Adaptive Recursion - arXiv, 1월 3, 2026에 액세스, <https://arxiv.org/html/2511.08653v2>
9. Enhancing Trust-Region Bayesian Optimization via Newton Methods - arXiv, 1월 3, 2026에 액세스, <https://arxiv.org/html/2508.18423v1>
10. Diffusion Policies Creating a Trust Region for Offline Reinforcement Learning - NIPS papers, 1월 3, 2026에 액세스, https://proceedings.neurips.cc/paper_files/paper/2024/file/59a48c111f97f2174709ea9ed8e920d1-Paper-Conference.pdf

11. ReStyle: A Residual-Based StyleGAN Encoder via Iterative Refinement - CVF Open Access, 1월 3, 2026에 액세스, https://openaccess.thecvf.com/content/ICCV2021/papers/Alaluf_ReStyle_A_Residual-Based_StyleGAN_Encoder_via_Iterative_Refinement_ICCV_2021_paper.pdf
12. A review on spectral data preprocessing techniques for machine learning and quantitative analysis - PubMed Central, 1월 3, 2026에 액세스, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12221524/>
13. A Deep Equilibrium Model for Remaining Useful Life Estimation of Aircraft Engines - MDPI, 1월 3, 2026에 액세스, <https://www.mdpi.com/2079-9292/14/12/2355>